

Đặc tả hệ thống — Home Credit Default Risk

Oct 7, 2026 · @vinh

Hệ thống chấm điểm rủi ro vỡ nợ cho đơn vay tiêu dùng, xây trên bộ dữ liệu Home Credit gồm 8 bảng quan hệ và khoảng 58,4 triệu dòng. Tài liệu này đặc tả dữ liệu nguồn, kiến trúc, quy trình xử lý, tiêu chí đánh giá và lộ trình triển khai.

Tổng quan

Bài toán nghiệp vụ

Home Credit cấp tín dụng tiêu dùng cho nhóm khách hàng thường không đủ điều kiện vay ngân hàng truyền thống, nhiều người trong số đó có lịch sử tín dụng mỏng hoặc không có. Câu hỏi cần trả lời tại thời điểm xét duyệt: **khách hàng này có khả năng gặp khó khăn trả nợ ở các kỳ đầu tiên không, và mức độ bao nhiêu.**

Từ chuỗi sai cả hai phía đều có chi phí. Từ chối một khách tốt làm mất doanh thu và đẩy họ sang kênh vay không chính thức. Duyệt một khách không có khả năng trả gây lỗ cho bên cho vay và đẩy khách vào nợ xấu. Hệ thống này phục vụ việc cân hai chi phí đó một cách định lượng.

Mục tiêu hệ thống

Hệ thống nhận hồ sơ đơn vay cùng toàn bộ lịch sử tín dụng liên quan, và sinh ra ba thứ:

1. **Xác suất vỡ nợ đã hiệu chỉnh** cho từng đơn, kèm điểm tín dụng quy đổi và dải xếp hạng.
2. **Một ngưỡng quyết định** gắn với cấu trúc chi phí, kèm tỷ lệ duyệt và tổn thất dự kiến tương ứng.
3. **Lớp báo cáo** cho phép theo dõi chất lượng danh mục và chất lượng chính mô hình.

Đầu ra bàn giao

Sản phẩm	Dạng	Điều kiện chấp nhận
Pipeline dữ liệu	mã nguồn Python có thể import	chạy lại toàn bộ từ CSV thô bằng một lệnh
Ma trận đặc trưng	Parquet có phiên bản	kèm manifest ghi cột và phép tổng hợp
Mô hình chấm điểm	artifact đã hiệu chỉnh	có reliability diagram và Brier score

Sản phẩm	Dạng	Điều kiện chấp nhận
Lớp dữ liệu BI	bảng trong SQL Server	ràng buộc khóa chính và khóa ngoại đầy đủ
Dashboard	báo cáo Power BI	bốn trang, nối trực tiếp vào SQL Server
Tài liệu kết quả	README	số liệu sinh tự động từ kết quả pipeline

Phạm vi

Trong phạm vi: xử lý dữ liệu theo lô, sinh đặc trưng, huấn luyện và hiệu chỉnh mô hình, chọn ngưỡng theo chi phí, kiểm tra công bằng, mô hình dữ liệu BI và dashboard.

Ngoài phạm vi: chấm điểm thời gian thực qua API, giám sát trôi dạt mô hình trong vận hành, hệ thống ra quyết định tự động, và tích hợp với hệ thống cấp tín dụng thật.

Ba giới hạn phải chấp nhận

Ba điều sau là thuộc tính của dữ liệu, không khắc phục được bằng kỹ thuật, và chúng ràng buộc những gì hệ thống có thể hứa:

- **Không có ngày tháng tuyệt đối.** Mọi mốc thời gian là số ngày hoặc số tháng tương đối so với ngày nộp đơn. Hệ quả: không dựng được bảng chiều ngày thực, không có phân tích xu hướng theo tháng dương lịch, và không kiểm định được mô hình theo trục thời gian.
- **Ngưỡng chính xác của nhãn không được công bố.** Xem mục biên mục tiêu. Hệ quả: xác suất đầu ra không dịch trực tiếp sang PD theo chuẩn Basel.
- **Tập `application_test.csv` không có nhãn.** Mọi đo lường phải dựa trên tập holdout tách ra từ `application_train.csv`.

Mô tả dữ liệu nguồn

Tám tập CSV, tổng khoảng 58,4 triệu dòng. Bảng trung tâm `application_train` chỉ chiếm 0,5% khối lượng; **99,5% số dòng nằm ở bốn bảng lịch sử theo tháng**. Đặc điểm này chi phối mọi quyết định về công nghệ và kiến trúc ở các mục sau.

Tập	Dòng	Cột	Grain (một dòng =)	Khóa
<code>application_train.csv</code>	307.511	122	một đơn vay đang xét duyệt	<code>SK_ID_CURR</code> (PK)

Tệp	Dòng	Cột	Grain (một dòng =)	Khóa
application_test.csv	48.744	121	như trên, không có cột TARGET	SK_ID_CURR (PK)
bureau.csv	1.716.428	17	một khoản vay tại tổ chức tín dụng khác	SK_ID_BUREAU (PK), SK_ID_CURR (FK)
bureau_balance.csv	27.299.925	3	một khoản vay bên ngoài × một tháng	SK_ID_BUREAU (FK)
previous_application.csv	1.670.214	37	một đơn vay trước tại Home Credit	SK_ID_PREV (PK), SK_ID_CURR (FK)
POS_CASH_balance.csv	10.001.358	8	một hợp đồng POS hoặc cash × một tháng	SK_ID_PREV (FK)
installments_payments.csv	13.605.401	8	một lần trả góp đã thực hiện	SK_ID_PREV (FK)
credit_card_balance.csv	3.840.312	23	một thẻ tín dụng × một tháng	SK_ID_PREV (FK)

Số dòng và cột của `bureau` và `bureau_balance` được đối chiếu với [phân tích của Ashok Harnal](#). Bộ dữ liệu gốc ở [Kaggle](#).

Nhóm trường trong bảng trung tâm

122 cột của `application_train` chia thành năm nhóm:

Nhóm	Số cột xấp xỉ	Ví dụ trường
Thông tin khoản vay	8	AMT_CREDIT , AMT_ANNUITY , AMT_GOODS_PRICE , NAME_CONTRACT_TYPE
Nhân khẩu và nghề nghiệp	20	DAYS_BIRTH , CODE_GENDER , OCCUPATION_TYPE , ORGANIZATION_TYPE

Nhóm	Số cột xấp xỉ	Ví dụ trường
Tài chính và tài sản	12	AMT_INCOME_TOTAL , FLAG_OWN_CAR , OWN_CAR_AGE , NAME_HOUSING_TYPE
Điểm tín dụng ngoài	3	EXT_SOURCE_1 , EXT_SOURCE_2 , EXT_SOURCE_3
Thuộc tính nơi ở và cờ hồ sơ	79	APARTMENTS_AVG , FLAG_DOCUMENT_* , AMT_REQ_CREDIT_BUREAU_*


Nhóm cuối chiếm gần hai phần ba số cột nhưng đóng góp ít nhất về sức mạnh dự báo. Trong đó, 47 cột mô tả đặc điểm căn hộ (diện tích, số tầng, vật liệu) có tỷ lệ thiếu rất cao và tương quan chặt với nhau theo ba biến thể `_AVG` , `_MODE` , `_MEDI` . Đặc tả xử lý nhóm này nằm ở mục feature engineering.

Sơ đồ quan hệ

Không bảng lịch sử nào nối trực tiếp về `application_train` . Bốn bảng lớn nhất đều nằm ở tầng ba và chỉ nối được qua `SK_ID_BUREAU` hoặc `SK_ID_PREV` . Vì vậy mọi đặc trưng từ tầng ba phải tổng hợp **hai lần**: trước hết về grain của tầng hai, sau đó về grain khách hàng.

Mọi lịch sử tín dụng nối về đơn vay qua hai khóa trung gian

Cấu trúc quan hệ ba tầng · mọi quan hệ đều là một-nhiều



quan hệ ba tầng · 7 bảng, 3 khóa

Hai điểm cần lưu ý khi hiện thực:

- Mọi quan hệ đều là một-nhiều theo chiều mũi tên. Một khách có thể có nhiều khoản vay bên ngoài, mỗi khoản có nhiều dòng lịch sử tháng.
- `installments_payments` không phải bảng theo tháng mà là bảng sự kiện: mỗi dòng là một lần trả thực tế. Đây là khác biệt quan trọng vì nó cho phép tính độ trễ trả nợ ở mức từng giao dịch.

Biến mục tiêu

Định nghĩa

`TARGET` là biến nhị phân trong `application_train`. Giá trị 1 nghĩa là khách hàng gặp khó khăn trả nợ: chậm thanh toán quá X ngày ở ít nhất một trong Y kỳ trả đầu tiên của khoản vay. Giá trị 0 là mọi trường hợp còn lại.

Hai tính chất của định nghĩa này có hệ quả trực tiếp đến thiết kế:

Nhãn neo ở cửa sổ cố định. Vì chỉ xét Y kỳ đầu, mọi đơn vay được quan sát trong cùng một độ dài thời gian kể từ khi giải ngân. Nhờ vậy nhãn không phụ thuộc vào việc khoản vay đã tắt toán hay chưa, và không cần loại trừ khoản vay đang chạy.

X và Y không được công bố. Không biết nhãn tương ứng với chậm 30, 60 hay 90 ngày, cũng không biết cửa sổ là 3 hay 6 kỳ. Hệ quả: xác suất mô hình sinh ra là xác suất của **sự kiện này**, không phải PD theo định nghĩa Basel, và không quy đổi trực tiếp sang tổn thất thực. Tài liệu kết quả phải nói rõ điều này.

Phân bố lớp

Lớp	Số đơn	Tỷ lệ
<code>TARGET = 0</code>	282.686	91,93%
<code>TARGET = 1</code>	24.825	8,07%
Tổng	307.511	100%

Tỷ lệ xấp xỉ 11,4 ca âm trên mỗi ca dương. Mức mất cân bằng này có ba hệ quả bắt buộc:

- Accuracy bị cầm dùm làm chỉ số đánh giá.** Dự đoán tất cả bằng 0 đạt accuracy 91,93% mà không phát hiện được ca vỡ nợ nào.
- Không dùng ngưỡng mặc định 0,5.** Ngưỡng phải chọn theo chi phí sai lầm, xem mục đặc tả đánh giá.
- Không dùng kỹ thuật sinh mẫu tổng hợp.** Tỷ lệ 11,4:1 nằm trong tầm xử lý của trọng số lớp. Sinh mẫu nhân tạo làm sai lệch xác suất đầu ra, phá đúng thứ hệ thống cần.

Chất lượng dữ liệu

Bảy giá trị đã biết

Bảy trường sau chứa giá trị không thể dùng trực tiếp. Xử lý ở lớp silver là **bắt buộc**, không phải tùy chọn.

Trường	Vấn đề	Xử lý bắt buộc
DAYS_EMPLOYED	giá trị 365243 là mã quy ước cho người không đi làm, chiếm khoảng 18% số dòng	chuyển thành null, thêm cờ FLAG_NO_EMPLOYMENT
DAYS_BIRTH	luôn mang giá trị âm	$AGE_YEARS = -DAYS_BIRTH / 365.25$
CODE_GENDER	4 dòng mang giá trị XNA	chuyển thành null, không gán giá trị thay thế
ORGANIZATION_TYPE	XNA khoảng 18%, trùng gần hết với nhóm nghỉ hưu	giữ thành hạng mục riêng, không coi là thiếu ngẫu nhiên
AMT_INCOME_TOTAL	có giá trị cực đoan tại 117.000.000	winsorize ở phân vị 99,9 hoặc lấy logarit; không xóa dòng
EXT_SOURCE_1	thiếu khoảng 56%	giữ null, thêm cờ thiếu
OWN_CAR_AGE	thiếu khoảng 66%	thiếu vì không sở hữu xe; giữ null, không điền 0

Trường **DAYS_EMPLOYED** là rủi ro cao nhất trong nhóm này. Bỏ qua nó làm sai toàn bộ thống kê về thâm niên công tác, và đưa một giá trị tương đương 1.000 năm vào mọi phép tính trung bình.

Trong các bảng lịch sử, hai mã **XNA** và **XAP** cũng đóng vai trò giá trị thiếu và cần xử lý tương tự.

Khoảng trống phủ dữ liệu

Hai khoảng trống sau quyết định cách viết phép join và cách xử lý null ở lớp đặc trưng.

Khoảng trống	Số liệu	Hệ quả thiết kế
Khoản vay bên ngoài không có lịch sử tháng	817.395 trên 1.716.428 dòng <code>bureau</code> có dữ liệu trong <code>bureau_balance</code> , tức khoảng 48%	dùng <code>LEFT JOIN</code> ; <code>INNER JOIN</code> sẽ làm mất hơn nửa lịch sử
Khách không có lịch sử tín dụng bên ngoài	<code>bureau</code> phủ 305.811 trên 307.511 khách; khoảng 1.700 khách không có bản ghi nào	giữ null, thêm cờ <code>FLAG_NO_BUREAU_HISTORY</code>


Nguyên tắc chung áp cho toàn hệ thống: **thiếu dữ liệu không phải giá trị không**. Một khách có `BURO_AMT_CREDIT_SUM_MEAN` bằng 0 nghĩa là đã từng vay với số tiền 0 đồng, khác hẳn khách chưa từng vay ở đâu. Điền 0 xóa mất phân biệt giữa khách hồ sơ mỏng và khách có lịch sử sạch — đúng nhóm mà bài toán này cần phân biệt nhất.

Kiến trúc hệ thống

Dữ liệu chạy một chiều qua tám bước. Mỗi bước là một hàm nhận đường dẫn vào và ghi ra đường dẫn mới; **không bước nào được ghi đè đầu vào của chính nó**, nhờ vậy chạy lại nhiều lần luôn cho cùng kết quả.

Dữ liệu chạy một chiều qua tám bước, từ CSV đến dashboard

Mỗi lớp ghi ra tệp mới · cột phải là công nghệ dùng ở lớp đó



kiến trúc lớp · 8 bước, một chiều

Nguyên tắc kiến trúc quan trọng nhất là **tách lớp tính toán khỏi lớp phục vụ**. DuckDB xử lý khối 58 triệu dòng và ghi kết quả ra Parquet; SQL Server chỉ chứa lớp mart nhỏ để Power BI truy vấn. Đưa dữ liệu thô vào SQL Server làm chậm cả hai phía mà không mang lại lợi ích nào.

Lớp tô màu là ràng buộc thứ tự duy nhất không được phép đảo: holdout phải tách xong trước khi bất kỳ phép tổng hợp nào chạy. Lý do và cơ chế nằm ở mục đặc tả huấn luyện.

Mô hình dữ liệu đầu ra

Hệ thống sinh ra **hai cấu trúc dữ liệu khác hình dạng, không dùng chung một bảng**. Chúng phục vụ hai loại truy cập khác nhau và không thể tối ưu đồng thời.

Cấu trúc A — ma trận huấn luyện

Một dòng một `SK_ID_CURR`, khoảng 500–800 cột sau tổng hợp. Rộng, phẳng, không chuẩn hóa, lưu dạng Parquet. Truy cập duy nhất là đọc toàn bộ vào bộ nhớ để huấn luyện, nên không cần index, không cần ràng buộc, và không nạp vào SQL Server.

Mỗi phiên bản ma trận phải đi kèm một tệp manifest ghi ba thứ: danh sách cột, phép tổng hợp sinh ra từng cột, và mã băm của dữ liệu nguồn. Không có manifest thì một cột tên `BURO_AMT_CREDIT_SUM_MEAN` không truy được về cách tính.

Cấu trúc B — star schema cho báo cáo

Hẹp, nhỏ, tên cột đọc được, khoảng 30 trường nghiệp vụ. Truy cập là truy vấn tổng hợp từ Power BI, nên cần index và ràng buộc đầy đủ.

Bảng	Grain	Khóa chính	Số dòng dự kiến
<code>Fact_Application</code>	một đơn vay	<code>SK_ID_CURR</code>	307.511
<code>Dim_Occupation</code>	nghề nghiệp	<code>OccupationKey</code>	19
<code>Dim_Organization</code>	loại tổ chức làm việc	<code>OrgKey</code>	59
<code>Dim_Education</code>	trình độ học vấn	<code>EducationKey</code>	6
<code>Dim_ContractType</code>	loại hợp đồng vay	<code>ContractKey</code>	3
<code>Dim_HousingType</code>	hình thức cư trú	<code>HousingKey</code>	7
<code>Dim_FamilyStatus</code>	tình trạng hôn nhân	<code>FamilyKey</code>	7
<code>Dim_AgeBand</code>	nhóm tuổi	<code>AgeBandKey</code>	7
<code>Dim_IncomeBand</code>	nhóm thu nhập	<code>IncomeBandKey</code>	6
<code>Dim_RiskBand</code>	dải điểm rủi ro	<code>RiskBandKey</code>	6

Số dòng dimension đã cộng thêm một dòng cho giá trị không xác định.

Cột của bảng fact

`Fact_Application` mang ba nhóm cột:

Nhóm	Cột
Khóa ngoại	<code>OccupationKey</code> , <code>OrgKey</code> , <code>EducationKey</code> , <code>ContractKey</code> , <code>HousingKey</code> , <code>FamilyKey</code> , <code>AgeBandKey</code> , <code>IncomeBandKey</code> , <code>RiskBandKey</code>

Nhóm	Cột
Số đo	AMT_CREDIT , AMT_ANNUITY , AMT_INCOME_TOTAL , AMT_GOODS_PRICE , CREDIT_INCOME_RATIO , ANNUITY_INCOME_RATIO
Kết quả mô hình	TARGET , PD_Predicted , CreditScore , Model_Version , IsHoldout

Cột `TARGET` và `PD_Predicted` nằm cạnh nhau trong cùng bảng fact là lựa chọn có chủ đích: nó cho phép dashboard đo chất lượng chính mô hình, không chỉ mô tả danh mục. Còn `IsHoldout` cho phép tách riêng phần chưa bao giờ được huấn luyện khi đọc chỉ số.

Ba quy tắc bắt buộc cho dimension

- Khóa là số nguyên tự sinh**, không dùng chuỗi nghiệp vụ làm khóa. Chuỗi dài không index được hiệu quả và dễ vỡ vì khác biệt khoảng trắng hoặc chữ hoa.
- Mỗi dimension có một dòng cho giá trị không xác định**, khóa `-1`. Nhờ vậy bảng fact không bao giờ chứa khóa ngoại null, và báo cáo không sinh dòng trống.
- Dimension có thứ tự tự nhiên phải có cột `SortOrder`**. Áp dụng cho `Dim_AgeBand`, `Dim_IncomeBand`, `Dim_RiskBand` và `Dim_Education`. Thiếu cột này, biểu đồ sẽ sắp nhóm theo bảng chữ cái.

Mỗi `SK_ID_CURR` xuất hiện đúng một lần trong `application_train`, nên **không phát sinh bài toán chiều biến đổi chậm**. Mọi thuộc tính đều là thuộc tính tại thời điểm nộp đơn và nằm trực tiếp trong bảng fact.

Tech stack

Tiêu chí chọn: mỗi công nghệ phải giải quyết một ràng buộc cụ thể của bộ dữ liệu này. Cột cuối nêu ràng buộc đó.

Lớp	Công nghệ	Ràng buộc nó giải quyết
Định dạng lưu trữ	Parquet	58,4 triệu dòng CSV đọc chậm và chiếm quá nhiều dung lượng
Tính toán tổng hợp	DuckDB	<code>bureau_balance</code> 27,3 triệu dòng vượt bộ nhớ khả dụng khi xử lý bằng DataFrame
Biến đổi bảng nhỏ	Polars hoặc pandas	<code>application_train</code> 307K dòng vừa bộ nhớ, thao tác cột linh hoạt hơn

Lớp	Công nghệ	Ràng buộc nó giải quyết
Thuật toán	LightGBM	xử lý null native, cần thiết vì EXT_SOURCE_1 thiếu 56% và OWN_CAR_AGE thiếu 66%
Khung pipeline ML	scikit-learn	Pipeline và ColumnTransformer giữ mọi phép biến đổi nằm trong fold
Hiệu chỉnh xác suất	CalibratedClassifierCV	trọng số lớp làm lệch xác suất đầu ra
Giải thích mô hình	SHAP TreeExplainer	cần giải thích ở cả mức tổng thể lẫn từng hồ sơ
Theo dõi thực nghiệm	MLflow	số lượng tổ hợp đặc trưng và siêu tham số vượt khả năng ghi chép thủ công
Kiểm chất lượng	Pandera và pytest	quality gate phải chạy được độc lập trong CI
Điều phối	Makefile, sau đó Prefect	yêu cầu chạy lại toàn pipeline bằng một lệnh
Kho phục vụ	SQL Server trên Docker	Power BI cần nguồn quan hệ có ràng buộc khóa
Báo cáo	Power BI	yêu cầu dashboard tương tác có tham số what-if
Môi trường	uv hoặc conda, pin phiên bản	kết quả phải tái tạo được trên máy khác

Ghi chú về ba lựa chọn

DuckDB ở lớp tổng hợp. bureau_balance có 27,3 triệu dòng × 3 cột. Đọc bằng pandas với kiểu suy mặc định int64 chiếm nhiều GB trước khi tính toán bắt đầu, và phép groupby nhân thêm bộ nhớ trung gian. DuckDB đọc Parquet theo cột và xử lý ngoài bộ nhớ khi cần, nên không phụ thuộc RAM. Viết bằng SQL thuần cũng dễ rà soát hơn chuỗi groupby().agg() lồng nhau.

LightGBM thay vì hồi quy logistic làm mô hình chính. Lý do kỹ thuật cụ thể: dữ liệu có tỷ lệ thiếu rất cao ở nhiều cột quan trọng, và bản thân việc thiếu là tín hiệu (khách không có xe, khách không có lịch sử tín dụng). Cây quyết định học được hướng rẽ của nhánh thiếu; hồi quy logistic buộc phải điền giá trị và làm mất tín hiệu đó.

SQL Server chỉ ở lớp phục vụ. Kho phục vụ chứa khoảng 307 nghìn dòng fact và vài trăm dòng dimension — nhỏ hơn dữ liệu thô khoảng 190 lần. Thiết lập một biên môi trường duy nhất cho cổng kết nối và dùng chung cho cả `docker-compose`, script nạp và chuỗi kết nối của Power BI.

Công nghệ không dùng

Công nghệ	Lý do loại
Spark	58 triệu dòng nằm trong tầm xử lý một máy; thêm JVM và cấu hình mà không thêm năng lực
Airflow	chi phí vận hành vượt nhu cầu của pipeline batch một người
SMOTE và biến thể	nội suy trên dữ liệu nhiều cột one-hot và nhiều null sinh mẫu không hợp lệ, và phá hiệu chỉnh xác suất
Mạng nơ-ron	trên dữ liệu bảng quy mô này, gradient boosting cho kết quả tốt hơn với chi phí thấp hơn

Đặc tả pipeline

Các bước xử lý

Mỗi bước là một hàm Python có thể import và kiểm thử độc lập. Notebook chỉ dùng để khám phá và trình bày, không chứa logic sản xuất.

1. **Ingest** — đọc 8 tệp CSV, ghi ra Parquet có nén, không thay đổi nội dung.
2. **Kiểm hợp đồng** — đối chiếu số dòng, số cột, kiểu dữ liệu và tính duy nhất khóa chính với đặc tả ở mục mô tả dữ liệu nguồn.
3. **Chuẩn hóa** — xử lý bảy bảy giá trị, đổi dấu các trường `DAYS_*`, sinh cờ thiếu. Một bảng silver cho mỗi bảng nguồn, giữ nguyên grain.
4. **Tách holdout** — rút 20% `SK_ID_CURR` theo phân tầng trên TARGET, ghi danh sách id ra tệp. Bước này **bắt buộc đứng trước bước 5**.
5. **Tổng hợp đặc trưng** — gộp 6 bảng lịch sử về grain khách hàng bằng SQL trên DuckDB, qua hai tầng tổng hợp.
6. **Kiểm chất lượng đặc trưng** — rà cột hồng và dấu hiệu rò rỉ trước khi huấn luyện.
7. **Huấn luyện và hiệu chỉnh** — CV 5 fold, ghi thực nghiệm vào MLflow, hiệu chỉnh xác suất, chọn ngưỡng theo chi phí.

8. Nạp lớp phục vụ — dựng dimension và fact, nạp vào SQL Server qua bảng tạm, tạo ràng buộc khóa, refresh Power BI.

Quality gate

Mỗi gate là một hàm trả về đạt hoặc không đạt, viết bằng Pandera hoặc pytest, chạy được độc lập với pipeline. Gate không được nhúng vào hàm nạp dữ liệu.

Bước	Điều kiện kiểm tra	Hành động khi không đạt
2	số dòng và số cột khớp đặc tả	dừng
2	<code>SK_ID_CURR</code> duy nhất trong <code>application_train</code>	dừng
2	<code>SK_ID_BUREAU</code> duy nhất trong <code>bureau</code>	dừng
3	không còn giá trị 365243 trong bất kỳ cột <code>DAYS_*</code>	dừng
3	mọi <code>DAYS_*</code> nhỏ hơn hoặc bằng 0 sau chuẩn hóa	dừng
4	giao giữa tập huấn luyện và holdout là rỗng	dừng
4	tỷ lệ TARGET hai tập lệch dưới 0,1 điểm phần trăm	dừng
5	số dòng sau mọi join bằng số đơn vay	dừng
6	không cột nào toàn null hoặc chỉ một giá trị	loại cột, ghi log
6	không cột nào chứa giá trị vô cực	dừng
6	không cột nào đạt AUC đơn biến trên 0,95	dừng và điều tra rò rỉ
7	AUC giữa các fold lệch dưới 0,02	cảnh báo
8	mọi khóa ngoại trong fact tồn tại trong dimension	dừng
8	số dòng fact bằng 307.511	dừng

Gate tại bước 6 về AUC đơn biến là lớp phòng thủ quan trọng nhất. Nguyên tắc: một cột đơn lẻ đạt AUC trên 0,95 trên bài toán rủi ro tín dụng gần như chắc chắn là dấu hiệu rò rỉ hoặc trùng lặp với nhãn, không phải phát hiện có giá trị. Để tham chiếu, cả ba cột `EXT_SOURCE_*` cộng lại chỉ đạt khoảng 0,70.

Đặc tả feature engineering

Nhiệm vụ: gộp 58 triệu dòng lịch sử về 307.511 dòng khách hàng mà không mất tín hiệu. Toàn bộ viết bằng SQL trên DuckDB.

Tổng hợp hai tầng

Bốn bảng lớn nhất nằm ở tầng ba nên phải gấp hai lần:

1. `bureau_balance` gấp về grain `SK_ID_BUREAU`, sau đó nối vào `bureau` và gấp tiếp về `SK_ID_CURR`.
2. `POS_CASH_balance`, `installments_payments`, `credit_card_balance` gấp về grain `SK_ID_PREV`, sau đó nối vào `previous_application` và gấp tiếp về `SK_ID_CURR`.

Mọi phép nối dùng `LEFT JOIN` tính từ bảng cha, vì tỷ lệ phủ không đầy đủ như đã nêu ở mục chất lượng dữ liệu.

Bốn họ đặc trưng

Họ	Cách tính	Số cột ước tính
Tỷ lệ tại đơn vay hiện tại	phép chia giữa các trường trong <code>application</code>	10–15
Tổng hợp toàn lịch sử	count, sum, mean, max, min, std theo từng bảng	250–350
Tổng hợp theo cửa sổ thời gian	như trên nhưng giới hạn 3, 6, 12, 24 tháng gần nhất	150–250
Xu hướng	<code>regr_slope</code> của số dư theo thời gian	20–40

Họ tỷ lệ rẻ nhất và thường nằm trong nhóm đặc trưng mạnh nhất. Sáu tỷ lệ cần có:

`AMT_CREDIT / AMT_INCOME_TOTAL`, `AMT_ANNUITY / AMT_INCOME_TOTAL`, `AMT_CREDIT / AMT_GOODS_PRICE`, `AMT_CREDIT / AMT_ANNUITY`, `DAYS_EMPLOYED / DAYS_BIRTH`, và `AMT_INCOME_TOTAL / CNT_FAM_MEMBERS`.

Họ cửa sổ thời gian là nơi tập trung giá trị cao nhất và thường bị bỏ qua. Hành vi trả nợ ba tháng gần nhất mang nhiều thông tin hơn hành vi bốn năm trước, nhưng phép tổng hợp toàn lịch sử làm loãng hai tín hiệu đó vào nhau.

Hai đặc trưng trọng yếu

Từ `installments_payments`, hai đại lượng sau đo trực tiếp hành vi trả nợ, không qua biến trung gian:

- `DAYS_ENTRY_PAYMENT - DAYS_INSTALLMENT` — số ngày trả muộn so với hạn. Lấy mean, max, và tỷ lệ số lần dương.
- `AMT_PAYMENT / AMT_INSTALLMENT` — tỷ lệ trả đủ. Giá trị dưới 1 là trả thiếu.

Về ba cột điểm tín dụng ngoài

`EXT_SOURCE_1`, `EXT_SOURCE_2`, `EXT_SOURCE_3` là điểm do bên thứ ba tính sẵn. Chúng hợp lệ vì có mặt tại thời điểm xét duyệt, nhưng chiếm tỷ trọng rất lớn trong sức mạnh dự báo.

Hệ thống vì vậy huấn luyện **hai câu hình đặc trưng song song**: câu hình đầy đủ cho hiệu năng tốt nhất, và câu hình không có `EXT_SOURCE_*` để đo sức mạnh của tín hiệu nội bộ. Câu hình thứ hai mới dùng được cho phân tích nghiệp vụ, vì nó chỉ ra yếu tố nào trong hồ sơ khách hàng thực sự liên quan đến rủi ro.

Kiểm soát số chiều

Làm đầy đủ bốn họ trên cho 6 bảng sinh ra hàng nghìn cột. Ba quy tắc giới hạn:

- Danh sách cột × phép tổng hợp khai báo trong tệp cấu hình YAML**, không dùng vòng lặp quét toàn bộ. Phép `std` trên một cờ nhị phân không mang thông tin.
- Nhóm 47 cột mô tả căn hộ rút gọn trước khi tổng hợp**. Ba biến thể `_AVG`, `_MODE`, `_MEDI` của cùng một thuộc tính tương quan rất chặt; giữ một biến thể, hoặc thay toàn nhóm bằng một chỉ số tổng hợp cộng một cờ đầy đủ thông tin.
- Lọc sau khi sinh, theo tiêu chí cố định trước**. Loại cột trên 95% null, cột chỉ một giá trị, và một trong hai cột có tương quan tuyệt đối trên 0,98. Tiêu chí phải cố định trước khi xem kết quả, không điều chỉnh theo AUC.

Quy tắc xử lý giá trị thiếu

Sau `LEFT JOIN`, khách không có lịch sử sẽ có toàn bộ cột tương ứng bằng null. **Giữ nguyên null và thêm cờ sự hiện diện**, không điền 0. LightGBM học được hướng rẽ của nhánh thiếu, nên chính sự vắng mặt trở thành đặc trưng có ích cho nhóm khách hồ sơ mỏng — nhóm trọng tâm của bài toán này.

Đặc tả huấn luyện

Chia dữ liệu ba tầng

Tầng	Tỷ lệ	Số đơn	Mục đích	Số lần truy cập
Holdout	20%	61.502	thử nghiệm cuối cùng	đúng một lần
Huấn luyện qua CV	80%	246.009	so sánh mô hình, dò siêu tham số	không giới hạn
Fold hiệu chỉnh	1 trong 5 fold	~49.202	hiệu chỉnh xác suất	mỗi lần huấn luyện

Holdout tách ở bước 4 của pipeline, trước mọi phép tính đặc trưng, và danh sách id được ghi ra tệp để cố định qua các lần chạy.

Lý do tách riêng holdout khỏi CV: sau nhiều lần thử nghiệm, điểm CV trở nên lạc quan vì chính các lựa chọn đã được tối ưu theo nó. Holdout giữ được tính độc lập chỉ khi không được dùng để ra bất kỳ quyết định nào.

Phương pháp kiểm định chéo

Stratified K-fold với k bằng 5, phân tầng theo TARGET.

Không dùng kiểm định theo thời gian, vì `application_train` không có cột ngày tháng nào, và `SK_ID_CURR` không đảm bảo tăng theo thời gian nộp đơn. Dùng id làm thay thế cho trục thời gian là giả định không kiểm chứng được; nếu sai nó tạo ra tập kiểm tra lệch phân bố mà không phát hiện được. Tài liệu kết quả phải nêu rõ lý do này.

Năm nguồn rò rỉ và biện pháp chặn

Dữ liệu nguồn đã neo sẵn tại thời điểm nộp đơn: mọi `DAYS_*` và `MONTHS_BALANCE` đều âm, tức chỉ chứa thông tin quá khứ. Rò rỉ vì vậy không đến từ dữ liệu mà từ quá trình xử lý.

Nguồn	Biểu hiện	Biện pháp chặn
Tổng hợp đặc trưng trước khi chia dữ liệu	AUC trên CV cao hơn holdout 0,02–0,05	tách holdout ở bước 4, trước bước 5
Target encoding tính ngoài fold	AUC CV rất cao, holdout sụt mạnh	tính encoding bên trong từng fold qua <code>Pipeline</code>
Điền thiếu bằng thống kê toàn tập	rò rỉ nhỏ nhưng có hệ thống	đưa imputer vào <code>Pipeline</code> , <code>fit</code> trong fold
Chuẩn hóa tính trên toàn tập	rò rỉ nhỏ	<code>fit</code> chỉ trên phần huấn luyện của fold
Cột trùng lặp hoặc sao chép nhãn	hai cột tương quan tuyệt đối bằng 1	gate tương quan và gate AUC đơn biến ở bước 6

Ràng buộc kỹ thuật: **mọi phép biến đổi phụ thuộc dữ liệu phải nằm trong `sklearn.pipeline.Pipeline`**, không chạy rời trước vòng CV. Điều này áp cho imputer, scaler, encoder và mọi bước chọn đặc trưng.

Hai kiểm định bắt buộc

Kiểm định AUC đơn biến. Với mỗi cột trong ma trận, tính `roc_auc_score(y, col)`. Cột vượt 0,95 phải điều tra trước khi huấn luyện. Chạy tự động ở gate bước 6.

Kiểm định bỏ đặc trưng. Với 5 đặc trưng có độ quan trọng cao nhất, huấn luyện lại mỗi lần loại một đặc trưng và ghi lại AUC. Kết quả đưa vào tài liệu dưới dạng bảng. Mục đích: phát hiện trường hợp một đặc trưng đơn lẻ gánh phần lớn hiệu năng, vì đó thường là dấu hiệu của rò rỉ hoặc của một biến thay thế nhân.

Trình tự mô hình

Bước	Mô hình	Mục đích	AUC tham chiếu
0	dự đoán hằng số theo tỷ lệ cơ sở	mốc chặn dưới	0,500
1	hồi quy logistic chỉ với <code>EXT_SOURCE_*</code>	đo sức mạnh điểm bên thứ ba	~0,70
2	hồi quy logistic với <code>application</code> và họ tỷ lệ	mốc cơ sở giải thích được	~0,74
3	LightGBM với toàn bộ đặc trưng	mô hình chính	0,78–0,79
4	LightGBM không dùng <code>EXT_SOURCE_*</code>	đo tín hiệu nội bộ	~0,74

Bước 0 và 1 bắt buộc phải chạy và báo cáo. Thiếu chúng, con số cuối cùng không có hệ quy chiếu để đánh giá.

Khoảng AUC hợp lý cho bộ dữ liệu này là **0,74 đến 0,80**. Giá trị vượt 0,85 phải được coi là cảnh báo rò rỉ và điều tra, không phải kết quả tốt.

Đặc tả đánh giá

Chỉ số kỹ thuật

Chỉ số	Dùng để	Ghi chú
AUC ROC	so sánh mô hình, báo cáo chính	chỉ đo khả năng xếp hạng
PR-AUC	đánh giá trên lớp thiểu số	nhạy hơn AUC khi mất cân bằng
Brier score	đo độ chính xác của xác suất	bắt buộc sau hiệu chỉnh
Reliability diagram	kiểm tra hiệu chỉnh trực quan	bắt buộc đưa vào tài liệu

Chỉ số	Dùng để	Ghi chú
Accuracy	không dùng	91,93% đạt được bằng cách đoán tất cả bằng 0

Độ chính xác của ước lượng

Kích thước holdout quyết định mức chính xác của con số báo cáo. Tính theo công thức Hanley–McNeil, quanh mức AUC 0,78:

Tỷ lệ holdout	Số đơn	Số ca dương	Sai số chuẩn	Khoảng tin cậy 95%
10%	30.751	2.482	0,0056	0,769 – 0,791
20%	61.502	4.964	0,0040	0,772 – 0,788
30%	92.253	7.447	0,0032	0,774 – 0,786

Chọn 20%. Ở mức này, khoảng tin cậy rộng khoảng 0,016, đủ để phân biệt hai mô hình chênh lệch 0,01 AUC một cách có ý nghĩa. Nhờ vậy việc chọn mô hình dựa trên bằng chứng, không dựa trên dao động ngẫu nhiên.

Mọi con số AUC trong tài liệu kết quả phải ghi kèm khoảng tin cậy.

Hiệu chỉnh xác suất

Quyết định cấp tín dụng cần xác suất đúng thang đo, không chỉ cần thứ tự xếp hạng. LightGBM kết hợp trọng số lớp cho ra xác suất lệch cao hơn thực tế, nên bước hiệu chỉnh là bắt buộc.

- Phương pháp: isotonic regression, phù hợp vì số mẫu lớn.
- Dữ liệu hiệu chỉnh: fold riêng, không dùng dữ liệu đã huấn luyện.
- Kiểm chứng: Brier score và reliability diagram. AUC không đổi sau hiệu chỉnh vì thứ tự xếp hạng không đổi; dùng AUC để kiểm tra hiệu chỉnh là sai.

Quy đổi sang điểm tín dụng

Xác suất sau hiệu chỉnh được quy đổi sang thang điểm theo công thức chuẩn của ngành:

$$\text{Score} = \text{Offset} - \text{Factor} \times \ln\left(\frac{p}{1-p}\right)$$

Tham số chọn sao cho tỷ lệ odds nhân đôi sau mỗi 20 điểm, neo tại 600 điểm. Điểm sau đó chia thành năm dải A đến E để đổ vào `Dim_RiskBand`.

Chỉ số nghiệp vụ

Ngưỡng quyết định chọn theo chi phí sai lầm, không dùng mặc định 0,5. Cấu trúc chi phí giả định như sau, và **phải được nêu rõ là giả định** trong mọi báo cáo:

Loại sai	Chi phí ước tính
Từ chối một khách không vỡ nợ	$AMT_CREDIT \times \text{biên lợi nhuận}$
Duyệt một khách vỡ nợ	$AMT_CREDIT \times \text{tỷ lệ tổn thất khi vỡ nợ}$

Từ cấu trúc này, hệ thống sinh ra đường tổn thất theo ngưỡng và xác định ngưỡng tối ưu. Ba chỉ số báo cáo kèm theo:

1. **Tỷ lệ duyệt** tại ngưỡng đã chọn.
2. **Tỷ lệ vỡ nợ trong nhóm được duyệt**, so với 8,07% của toàn bộ.
3. **Bảng phân vị mười phần**, hiển thị tỷ lệ vỡ nợ thực tế theo từng decile điểm. Điều kiện chấp nhận: tỷ lệ phải giảm đơn điệu từ decile rủi ro cao nhất xuống thấp nhất.

Bảng decile là chỉ số dễ đọc nhất với người không làm kỹ thuật, vì nó trả lời trực tiếp câu hỏi từ chối 10% rủi ro nhất thì tránh được bao nhiêu phần vỡ nợ.

Kiểm tra công bằng

Dữ liệu chứa `CODE_GENDER` và `DAYS_BIRTH`. Cho vay tiêu dùng chịu ràng buộc pháp lý về phân biệt đối xử theo giới tính và tuổi ở nhiều thị trường, nên ba phép đo sau là bắt buộc, tính trên holdout:

Phép đo	Câu hỏi
Tỷ lệ duyệt theo nhóm	nhóm nào bị từ chối nhiều hơn tại cùng một ngưỡng
AUC theo nhóm	mô hình có chính xác đều giữa các nhóm không
Độ hiệu chỉnh theo nhóm	PD dự báo có khớp tỷ lệ vỡ nợ thực tế trong từng nhóm không

Phép thứ ba quan trọng nhất: nếu mô hình ước lượng rủi ro của một nhóm cao hơn thực tế, nhóm đó bị định giá bất lợi một cách có hệ thống dù rủi ro thực tương đương. Đây là bất công đo được bằng số liệu.

Phạm vi dùng ở đo và báo cáo. Khắc phục thiên lệch không nằm trong phạm vi, nhưng kết quả đo phải được công bố kể cả khi bất lợi.

Lớp phục vụ và dashboard

Nạp dữ liệu vào SQL Server

Mỗi lần chạy, pipeline ghi vào bảng tạm `stg_*` trước, sau đó đổi tên trong một giao dịch duy nhất. Bảng đích không bao giờ ở trạng thái dở dang khi Power BI đang đọc.

Ba ràng buộc kỹ thuật:

1. **Độ dài cột chuỗi khai báo theo giá trị thực tế**, không đặt `NVARCHAR(4000)` cho mọi cột. Cột quá dài vượt giới hạn khóa 1700 byte và không index được.
2. **Tạo PRIMARY KEY và FOREIGN KEY thật sau khi đổi tên**. Ràng buộc ở tầng cơ sở dữ liệu bắt được lỗi mà kiểm tra ở tầng ứng dụng bỏ sót.
3. **Một biến môi trường duy nhất cho cổng kết nối**, dùng chung cho `docker-compose`, script nạp và chuỗi kết nối Power BI. Lệnh cổng giữa ba nơi này là lỗi thường gặp và khó phát hiện.

Các trang báo cáo

Trang	Câu hỏi trả lời	Nội dung chính
Danh mục	cơ cấu đơn vay như thế nào	số đơn, giá trị, tỷ lệ vỡ nợ theo loại hợp đồng, nghề, trình độ
Yếu tố rủi ro	nhóm nào rủi ro hơn	tỷ lệ vỡ nợ theo nhóm tuổi, thu nhập, hình thức cư trú, tình trạng hôn nhân
Chất lượng mô hình	mô hình hoạt động tốt đến đâu	bảng decile, reliability diagram, AUC trên holdout
Ngưỡng quyết định	nên đặt ngưỡng ở đâu	tham số what-if, tỷ lệ duyệt và tổn thất dự kiến theo ngưỡng

Trang **Ngưỡng quyết định** là thành phần biến báo cáo thành công cụ ra quyết định: một tham số what-if điều chỉnh ngưỡng PD, hai measure tính tỷ lệ duyệt và tổn thất dự kiến tương ứng.

Trang **Chất lượng mô hình** chỉ đọc dữ liệu có `IsHoldout = 1`, vì đây là phần duy nhất mô hình chưa từng thấy.

Measure cần có

Measure	Công thức	Định dạng
Tỷ lệ vỡ nợ thực tế	<code>DIVIDE(SUM(TARGET), COUNTROWS(Fact_Application))</code>	phần trăm
PD trung bình	<code>AVERAGE(PD_Predicted)</code>	phần trăm
Chênh lệch hiệu chỉnh	<code>[PD trung bình] - [Tỷ lệ vỡ nợ thực tế]</code>	điểm phần trăm
Tỷ lệ duyệt	<code>DIVIDE(COUNTROWS(FILTER(..., PD < Ngưỡng)), COUNTROWS(...))</code>	phần trăm
Số đơn vay	<code>COUNTROWS(Fact_Application)</code>	số nguyên

Measure **Chênh lệch hiệu chỉnh** là thành phần quan trọng nhất của trang chất lượng mô hình: nó cho thấy mô hình ước lượng cao hay thấp hơn thực tế trong từng lát cắt. Cắt theo giới tính và nhóm tuổi, chính measure này thực hiện phép kiểm tra công bằng thứ ba ở mục đánh giá.

Bốn quy tắc cho mô hình ngữ nghĩa

1. **Mọi quan hệ là một chiều**, từ bảng fact sang dimension. Quan hệ hai chiều làm mẫu số của các measure tỷ lệ bị lọc theo điều kiện của tử số, cho ra kết quả bằng 100%.
2. **Quan hệ tạo thủ công**, không dùng tính năng tự động phát hiện.
3. **Ngưỡng trong biểu thức DAX viết dưới dạng phân số**. Hàm `DIVIDE` trả về giá trị trong khoảng 0 đến 1, nên điều kiện so sánh phải viết `> 0.07`, không viết `> 7`. Định dạng phần trăm đặt ở thuộc tính hiển thị.
4. **Tất tính năng ngày tháng tự động**. Dữ liệu không có cột ngày nào, nên tính năng này chỉ sinh bảng ẩn vô ích và làm phình mô hình.

Riêng với cột cờ và cột tỷ lệ như `TARGET`, `PD_Predicted`, `CREDIT_INCOME_RATIO`, đặt thuộc tính tổng hợp mặc định là không tổng hợp. Để mặc định là tính tổng sẽ cho ra con số vô nghĩa khi kéo vào biểu đồ.

Về dữ liệu cá nhân


Bộ dữ liệu không chứa tên, số điện thoại hay địa chỉ. Định danh duy nhất là `SK_ID_CURR`, một số nguyên vô danh. Báo cáo vì vậy có thể công bố công khai mà không phát sinh rủi ro dữ liệu cá nhân. Không bổ sung tên giả cho mục đích trình bày, vì điều đó tạo ấn tượng sai rằng báo cáo chứa hồ sơ khách hàng thật.

Lộ trình triển khai

Sáu giai đoạn, mỗi giai đoạn kết thúc bằng một điều kiện kiểm chứng được bằng mã chạy tự động. Giai đoạn không qua cổng thì không chuyển tiếp, vì mọi giai đoạn sau đều dựa trên kết quả của nó.

Mỗi giai đoạn kết thúc bằng một cổng kiểm tra đo được

Sáu giai đoạn · hình thoi là cổng kiểm tra



lộ trình 6 tuần · 6 cổng kiểm tra

Thứ tự hai giai đoạn giữa là ràng buộc có chủ đích: **môc cơ sở và kiểm định rò rỉ đứng trước mô hình chính**. Lý do: một kết quả cao đạt được trước khi có hệ quy chiếu rất khó được xem xét lại một cách khách quan.

Nếu thời gian rút xuống ba tuần, giữ nguyên giai đoạn 1 đến 4 và bỏ giai đoạn 5 cùng phần công bằng của giai đoạn 6. Pipeline đúng kèm mô hình đã kiểm định rò rỉ là phần lõi; dashboard là lớp trình bày bên trên.

Tiêu chí nghiệm thu

Hệ thống được coi là hoàn thành khi thỏa đủ mười bốn điều kiện sau. Mỗi điều kiện kiểm chứng được bằng cách chạy mã hoặc đọc tài liệu, không dựa trên đánh giá chủ quan.

Về pipeline

- ☐ Chạy lại toàn bộ từ dữ liệu thô trên máy sạch bằng một lệnh duy nhất
- ☐ Không bước nào ghi đè đầu vào của chính nó; chạy hai lần cho kết quả giống nhau
- ☐ Toàn bộ quality gate ở bước 2, 3, 4, 5, 6, 8 đều đạt
- ☐ Logic sản xuất nằm trong module Python import được, không nằm trong notebook
- ☐ Phiên bản thư viện được pin; môi trường tái tạo được trên máy khác

Về tính đúng đắn của mô hình

- ☐ Holdout được tách trước mọi phép tính đặc trưng, và chỉ được đọc một lần
- ☐ Kiểm định AUC đơn biến đã chạy; không cột nào vượt 0,95
- ☐ Kiểm định bỏ đặc trưng đã chạy cho 5 đặc trưng mạnh nhất, kết quả đưa vào tài liệu
- ☐ Mọi phép biến đổi phụ thuộc dữ liệu nằm trong `Pipeline`, không chạy trước CV
- ☐ AUC trên holdout nằm trong khoảng 0,74–0,80, hoặc có giải trình nếu vượt

Về kết quả báo cáo

- ☐ Đã báo cáo mốc cơ sở: tỷ lệ nền và mô hình chỉ dùng `EXT_SOURCE_*`
- ☐ Xác suất đã hiệu chỉnh, có reliability diagram và Brier score
- ☐ Ngưỡng quyết định gắn với cấu trúc chi phí, kèm bảng decile
- ☐ Mọi con số AUC ghi kèm khoảng tin cậy
- ☐ Đã đo và công bố ba phép kiểm tra công bằng theo giới tính và nhóm tuổi

Về lớp phục vụ

- ☐ Mọi quan hệ trong mô hình ngữ nghĩa là một chiều, mọi ngưỡng DAX dạng phân số
- ☐ Bốn trang báo cáo hoạt động, đọc trực tiếp từ SQL Server

Về tài liệu

Tài liệu kết quả phải nêu rõ ba giới hạn đã xác định ở mục tổng quan: dữ liệu không có ngày tháng tuyệt đối nên không kiểm định được theo thời gian; ngưỡng X và Y của nhãn không được công bố nên xác suất không quy đổi trực tiếp sang PD chuẩn ngành; và `application_test.csv` không có nhãn nên mọi đo lường dựa trên holdout tự tách.

Phần số liệu trong tài liệu sinh tự động từ kết quả pipeline, không chép thủ công. Một script đọc chỉ số từ MLflow và ghi vào tài liệu giữa hai dòng đánh dấu là đủ. Điều này loại bỏ khả năng tài liệu lệch khỏi mã sau mỗi lần chạy lại.